一些基础概念

凸集

仿射集

凸锥

$\theta_1 x_1 + \theta_2 x_2 \in C$

$\forall \theta_1+\theta_2=1,\ \theta_1,\theta_2>0$

$\forall \theta_1+\theta_2=1,\ \theta_1,\theta_2 \in \mathbb{R}$

$\forall \theta_1,\theta_2>0$

↳ 对应三种组合 → 对应三个包

常见凸集：

超平面 $\{x \in \mathbb{R}^n \mid a^T x = b\}$

半空间 $\{x \in \mathbb{R}^n \mid a^T x \le b\}$

范数球 $\{x \in \mathbb{R}^n \mid \|x - x_c\|_p \le r\}$

多面体

单纯形：$k+1$ 个点 v_0 相减得 $v_1-v_0, v_2-v_0, \dots, v_k-v_0$ 线性无关

$C = \mathrm{conv}\{v_0, \dots, v_k\}$

保凸运算

交集

仿射：$f(x) = Ax + b$

缩放：$\alpha S = \{\alpha x \mid x \in S\}$

位移：$\alpha + S = \{\alpha + x \mid x \in S\}$

加：$S_1 + S_2 = \{x+y \mid x \in S_1, y \in S_2\}$

直积：$S_1 \times S_2 = \{(x, y) \mid x \in S_1, y \in S_2\}$

凸函数：

$f(\theta x+(1-\theta)y) \le \theta f(x)+(1-\theta)f(y)$

↓

< 严格凸

$-\theta(1-\theta)\|x-y\|^2$ 强凸



$\therefore$ $\mathrm{dom} f$ 是凸集

一阶条件：

$f(y) \ge f(x)+\nabla f(x)^T(y-x)$

$\nabla f(x^*)^T=0 \iff x^*$ 是最小值 $x^*=\arg\min_{x\in\mathbb{R}^n} f(x)$

二阶条件：

凸函数 $\iff \nabla^2 f(x) \ge 0$

α-次水平集：

$C_\alpha=\{x\in \mathrm{dom} f: f(x)\le \alpha\}$ 相当于等高面

拟凸函数 若定义域内所有非空 α-次水平集都为凸

凸优化问题

目标函数为凸可行集合为凸的极小化问题

$\min_x f(x)$ s.t. $x\in\Omega$. f 为凸函数 Ω 为凸集

拉格朗日乘数法.

对一个有可行域限制的已极最值问题.

$L(x,\lambda)$ 的最值情况与原问题一致

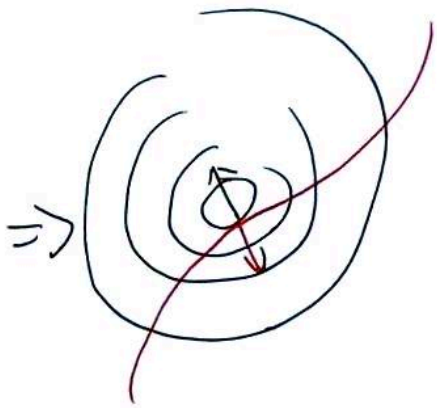
例：求 $f(x,y)$ 的 min. 且 $y=g(x)$.

$$L(x,y,\lambda)=f(x,y)+\lambda(y-g(x)) \quad \lambda\geq 0.$$

$$\nabla L(x,y,\lambda)=0$$

$$\Downarrow$$

$$\begin{cases}\dfrac{\partial f(x,y)}{\partial x}+\lambda\dfrac{\partial(y-g(x))}{\partial x}=0\\ \dfrac{\partial f(x,y)}{\partial y}+\lambda\dfrac{\partial(y-g(x))}{\partial y}=0.\end{cases}$$



找同向 λ 调节，才可能为 0.



仅几约束可以组合使和为0.

$g_\alpha(x^*)=g_\beta(x^*)=0.$

$\lambda_\alpha\nabla g_\alpha(x^*)+\lambda_\beta\nabla g_\beta(x^*)=-\nabla f(x^*)$ 紧致的 起了作用!

其它 $g_i(x^*)\neq 0<0$.

但梯度 $\lambda_i\nabla g_i(x)=0 \Rightarrow \lambda_i=0$. 非 α,β

松弛的（无起作用）.

原因：$\lambda\geq 0$. 其两两组合不可能与 ∇f 抵消.

对一个凸问题，上述方法已经OK了。

但对一个非凸问题呢？可以看其 **L对偶问题**。

$$\min f_0(x),\ x\in\mathbb{R}^n$$

$$s.t.\ f_i(x)\le 0,\quad h_i(x)=0 \quad \text{可行域 } \mathcal{X}$$

$$L(x,\lambda,\nu)=f_0(x)+\sum_{i=1}^{m}\lambda_i f_i(x)+\sum_{i=1}^{p}\nu_i h_i(x),\quad \text{可行域 } =\mathbb{R}^n$$

原问题：$\min\limits_{x}\max\limits_{\lambda,\nu} L(x,\lambda,\nu)$

$$s.t.\ \lambda\succeq 0$$

- x 不在原可行域 $\mathcal{X}$ 内：$\max\limits_{\lambda,\nu} L(x,\lambda,\nu)=f_0(x)+\underbrace{\infty}_{f_i\le 0,\lambda_i\neq 0}+\underbrace{\infty}_{h_i\neq 0,\nu_i}=\infty$
- x 在原可行域 $\mathcal{X}$ 内：$\max\limits_{\lambda,\nu} L(x,\lambda,\nu)=f_0(x)+\underbrace{0}_{f_i\le 0,\lambda_i\succeq 0}+\underbrace{0}_{h_i=0}=f_0(x)$

$\Big\}\ \min$

对偶问题：（交换顺序）

先 对偶函数：$g(\lambda,\nu)=\min\limits_{x} L(x,\lambda,\nu)$

$$\max_{\lambda,\nu} g(\lambda,\nu)=\max_{\lambda,\nu}\left[\min_{x} L(x,\lambda,\nu)\right],\quad \text{可行域 } x\in\mathbb{R}^n$$

$$s.t.\ \lambda\succeq 0$$

$\nabla_x L(x,\lambda,\nu)=0$

是无约束么？ NO!!

不论原问题是什么，其对偶问题都是一个凸问题。

因为 $\min\limits_{x} L(x,\lambda,\nu)$ 得到了一个 x^*。

~~对偶函数~~ $\max\limits_{\lambda,\nu} g(\lambda,\nu)=f_0(x^*)+\sum\lambda_i f_i(x^*)+\sum\nu_i h_i(x^*)$ ⇒ 直线（凹凸函数）

$f_0(x^*)$：常数；$\sum\lambda_i f_i(x^*)$：常数；$\sum\nu_i h_i(x^*)$：常数。

$\max g(\lambda,\nu)$ 是凸优化问题。

拉：$L(x,\lambda,v)=f_0(x)+\sum_i \lambda_i f_i(x)+\sum_i v_i h_i(x)$.

有 $\max_{\lambda v} L(x,\lambda,v) \geq L(x,\lambda,v) \geq \min_{x} L(x,\lambda,v)$.

$A(x) \geq I(\lambda,v)$.

原问题解 $p^*=\min_x(A(x)) \geq \max_{\lambda,v}(I(\lambda,v))=D^*$ 对偶问题解.

? 何时相等呢?

$>$ 弱对偶　$=$ 强对偶

Slater条件:

存在一个 $x\in D$ 的相对内点，

使得 $f_i(x)<0$.

则为强对偶问题. 充分条件.

必要条件? KKT条件 (有点像求导求最值).

① 原问题可行 $\begin{cases} f_i(x^*)\leq 0 \\ h_i(x^*)=0 \end{cases}$

② 对偶问题可行. $\begin{cases} \nabla_x L(x^*,\lambda^*,v^*)=0. \\ \lambda^*\geq 0. \end{cases}$

③ 互补松弛. $\lambda_i f_i(x)=0$. → 紧致点. $\nabla f_i\neq 0$. 有关联. $\lambda>0$. 但 $f_i(x)=0$.

松弛点. $\nabla f_i\neq 0$. 无关联 $\lambda=0$. f_i 可以 <0.

最优化理论

第二章作业. 廖伟然, 233233068

1. 由题有线性规划问题:

$$\min_{x\in\mathbb{R}^n} \ c^T x \qquad \text{原问题 (可行域 } D=\{x\}\text{)}.$$

$$\text{s.t.} \ \ Gx \le h$$

$$Ax = b, \quad G\in\mathbb{R}^{m_1\times n} \ A\in\mathbb{R}^{m_2\times n} \ h\in\mathbb{R}^{m_1} \ b\in\mathbb{R}^{m_2} \ c\in\mathbb{R}^n$$

设拉格朗日乘子为 λ, ν. 其中 $\lambda\in\mathbb{R}^{m_1}$ $h\in\mathbb{R}^{m_2}$ $\lambda\ge 0$.

拉格朗日函数 $L(x,\lambda,\nu) = c^Tx + \lambda^T(Gx-h) + \nu^T(Ax-b)$.

$(1\times n)$ $(1\times m)(m\times n)$ $(1\times m)(m\times 1)$

$$= c^Tx + \lambda^TGx - \lambda^Th + \nu^TAx - \nu^Tb.$$

$$= (c^T + \lambda^TG + \nu^TA)x - \lambda^Th - \nu^Tb$$

对偶函数 $g(\lambda,\nu) = \inf_x L(x,\lambda,\nu). \quad x\in\mathbb{R}^n$

$$= \inf_{x\in\mathbb{R}^n} \big(\underbrace{(c^T + \lambda^TG + \nu^TA)}_{K} x - \lambda^Th - \nu^Tb \big).$$

注: 此时 λ, ν^T 视为常数. 若 $K\neq 0$ $x\in\mathbb{R}^n$ 必能无穷小, 否则为常数

故

$$= \begin{cases} -\lambda^Th - \nu^Tb. & K=0. \\ -\infty & K\neq 0 \end{cases}$$

则对偶问题为: $\sup_{\lambda,\nu} \ -\lambda^Th - \nu^Tb. \ \text{s.t.} \ K=0 \ . \ \lambda\ge 0.$

下面推导KKT条件. 设最优解为 x^*, λ^*, v^*.

① 原始可行性

$$\underline{Gx^* \le h.}$$

$$\underline{Ax = b.}$$

② 对偶可行性

$$\nabla_x L(x, \lambda, v)\big|_{x=x^*} = 0 \Rightarrow \nabla_x \left[(c^T + x^T G + v^T A)x - \lambda^T h - v^T b\right]\big|_{x=x^*} = 0$$

逐项求导: (1) $\frac{\partial}{\partial x_k}(c^T x) = \frac{\partial}{\partial x_k}\sum_{j=1}^{n} c_j x_j = c_k$

$$\nabla_x (c^T x) = c$$

(2) $\frac{\partial}{\partial x_k}(\lambda^T G x) = \frac{\partial}{\partial x_k}\sum_{i=1}^{m} \lambda_i (G_{i\cdot} x) = \frac{\partial}{\partial x_k}\left(\sum_{i=1}^{m} \lambda_i \left(\sum_{j=1}^{n} G_{ij} x_j\right)\right)$

$$= \sum_{i=1}^{m} \lambda_i \frac{\partial}{\partial x_k}\left(\sum_{j=1}^{n} G_{ij} x_j\right) = \sum_{i=1}^{m} \lambda_i G_{ik}.$$

$$= G_{\cdot k}^T \lambda$$

$$\nabla_x (\lambda^T G x) = G^T \lambda.$$

(3) 同理 $\nabla_x (v^T A x) = A^T v$

故 $\nabla_x L(x, \lambda, v)\big|_{x=x^*} = 0 \Rightarrow \underline{c + G^T \lambda^* + A^T v^* = 0.}$

$$\underline{\text{且 } \lambda^* \ge 0}$$

③ 互补松弛条件.

$$\lambda_i ((Gx)_i - h_i) = 0 \quad i = 1 \cdots m_1.$$

即 $\lambda_i^* (Gx^* - h) = 0.$

2、有问题：

$$\min_{x\in\mathbb{R}^n} \frac{1}{\gamma}\|x-x_0\|_2^2+\sum_{i=1}^{N}\|A_ix+b_i\|_2$$

其中 $A_i\in\mathbb{R}^{m_i\times n}$ $b_i\in\mathbb{R}^{m_i}$ $x_0\in\mathbb{R}^n$ 要求其对偶问题.

引入 $y_i=A_ix+b_i$ 及新的等式约束 $y_i=A_ix+b_i$

原问题等价为 $\min_{x\in\mathbb{R}^n} \frac{1}{\gamma}\|x-x_0\|_2^2+\sum_{i=1}^{N}\|y_i\|_2$

$$s.t.\ -y_i+A_ix+b_i=0,\quad i=1,2\cdots N.$$

考虑多变量的拉格朗日对偶函数.

$$L(x,y,\lambda)=\frac{1}{\gamma}\|x-x_0\|_2^2+\sum_{i=1}^{N}\|y_i\|_2+\sum_{i=1}^{N}\lambda_i^T(-y_i+A_ix+b_i)$$

引对偶函数 $g_{\lambda,v}=\inf_{x,y} L(x,y,\lambda)$. 右(入统为常数)

对 y_i 看 $\sum_{i=1}^{N}\|y_i\|_2-\sum_{i=1}^{N}\lambda_i^Ty_i$

① 当 $\|\lambda_i\|_2\le 1$. $\lambda_i^Ty_i\le\|\lambda_i\|_2\|y_i\|_2\le\|y_i\|_2$. 故有 $g_{\lambda,v}\ge 0$. 当且仅当 $y_i=0$. "=" 成立

② 当 $\|\lambda_i\|_2>1$ 时. y_i 任意取. $\inf=-\infty$.

故 $\inf\{\sum_{i=1}^{N}\|y_i\|_2-\sum_{i=1}^{N}\lambda_i^Ty_i\}=\begin{cases}0, & y_i=0\\ -\infty, & \text{otherwise}\end{cases}$

对 x 考虑 $\frac{1}{\gamma}\|x-x_0\|_2^2+\underbrace{\sum\lambda_i^TA_i}_{c^T}x$ 为二次凸函数.

最小值在梯度为0点取得. $x^*=x_0-c$ 最小值为 $c^Tx_0-\frac{1}{\gamma}\|c\|_2^2$

综上 $g(\lambda)=\begin{cases}\sum_{i=1}^{N}\lambda_i^T(A_ix_0+b_i)-\frac{1}{\gamma}\|\sum A_i^T\lambda_i\|_2^2, & \|\lambda_i\|\le 1\\ -\infty, & \text{otherwise}\end{cases}$

~~故对偶问题~~ s.t. $\|\lambda_i\|\le 1$

故对偶问题为

$$\sup_{\lambda_i \sim \lambda_N} \sum_{i=1}^{N} \lambda_i (A_i x_0 + b_i) - \frac{1}{\gamma} \| \sum_{i=1}^{N} A_i^T \lambda_i \|_2^2$$

$$s.t. \ \|\lambda_i\|_2 \le 1, \quad i = 1, 2, \cdots N$$

3. 推导下列问题的对偶问题.

(1) $\min_{x \in \mathbb{R}^n} \|x\|_1 \quad s.t. \ Ax = b. \quad A \in \mathbb{R}^{m \times n} \quad b \in \mathbb{R}^m.$

设拉格朗日乘子为 $v \in \mathbb{R}^m$

$$L(x, v) = \|x\|_1 + v^T (Ax - b)$$

$$= \|x\|_1 + v^T A x - v^T b.$$

对偶函数 $g(v) = \inf_x L(x, v)$

考虑 $\inf_x \|x\|_1 + v^T A x$

令 $v^T A = c^T$ 上式 $\Leftrightarrow \inf_x \{\|x\|_1 + c^T x\}$

~~若 $\|c\|_1 > 1$~~ 等于 若 $\|c^T\|_\infty > 1$

当 v 使得 $|c_i| > 1$ 只需令 x_i 与其反号, 即可达到 $-\infty$

即当 $\|c^T\|_\infty \le 1$. $\|x\|_1 + c^T x \ge 0$. 当 $x = 0$ 时 "=" 成立.

因此 $g(v) = \begin{cases} -v^T b & \|v^T A\| \le 1. \\ -\infty & otherwise. \end{cases}$

所以对偶问题为 $\max -b^T v$

$$s.t. \ \|A^T v\|_\infty \le 1.$$

(2) $\min_{x\in\mathbb{R}^n} \|Ax-b\|_1$ $A\in\mathbb{R}^{m\times n}$ $b\in\mathbb{R}^m$.

令 $y = Ax-b$.

原问题等价于 $\min_{y\in\mathbb{R}^m} \|y\|_1$ s.t. $Ax-b-y=0$.

令 l 范数 $v\in\mathbb{R}^m$.

$$L(x,y,v) = \|y\|_1 + v^T(Ax-b-y)$$

$$= \|y\|_1 - v^Ty + v^TAx - v^Tb$$

对偶函数 $g(v) = \inf_{x,y} L(x,y,v)$.

分别求下确界.

i) 对于 $\inf_y[\|y\|_1 - v^Ty]$. 同(1)题可得 $\inf_y[\|y\|_1 - v^Ty] = \begin{cases} 0 & \|v\|_\infty \le 1 \\ -\infty & \text{其它} \end{cases}$

ii) 对于 $\inf_x v^TAx = \begin{cases} 0 & v^TA=0 \text{ (注: 0代表 } \vec{0} \text{ 是为 } 1\times n \text{ 的矩阵} \\ -\infty & \text{其它} \end{cases} \Leftrightarrow A^Tv=\vec{0}$

综上有 $g(v) = \begin{cases} -v^Tb & \text{当 } \|v\|_\infty \le 1,\ v^TA=0^{1\times n} \Leftrightarrow A^Tv=\vec{0} \\ -\infty & \text{其它} \end{cases}$

故对偶问题为 $\max\ g(v) = \max\ -v^Tb$.

s.t. $\|v\|_\infty \le 1$. $v^TA=0$.

最优化算法简介

基本思路：新解 = 旧解 + 步长 × 方向

↳ fixed ↓ 精确 / 非精确搜索

无约束：$\nabla f(x)=0$ 或 $0 \in \partial f(x)$ ⟶ $\min_x f(x)$ | 又称求解 用迭代 终止 $\|\nabla f(x)\|$

一阶
- 梯度下降法 经典
- 次梯度法 不可微
- 邻近梯度法 不可微但有结构

} 对条件数敏感

二阶
- 牛顿法 经典
- 拟牛顿法 降复杂度

} 对条件数不敏感

有约束

罚方法 增广拉格朗日法 交替方向乘子法

无约束优化算法

线搜索

方向 ↓ { 梯度下降：$-\nabla f(x_k)$
牛顿：$-H^{-1}\nabla f(x_k)$

why：经典迭代：$x_{k+1} = x_k + \alpha_k d_k$

↑ 步长 走多远？线搜索解决此问题

How：辅助函数 $\varphi(\alpha)$

将目标函数限制在一条射线上 $\varphi(\alpha) := f(x_k + \alpha d_k)$

↑ 固定 ↑ 固定

多维优化 → 一维函数 $\varphi(\alpha)$ 的最小化

目标 $\min_{\alpha \geq 0} \varphi(\alpha)$ ①

精确线搜索：

思想：在当前方向上，将步长走到理论最优 $\alpha_k = \arg\min_{\alpha \geq 0} \varphi(\alpha)$

代价：需将①解得比较彻底，计算量大。

前提：f 沿 d_k 为下降方向 $\Rightarrow$ $\varphi(\alpha)$ 是下单峰函数 ✓

二分法：若可导，二分找 $\varphi'(\alpha)=0$ 的点。

选左、右端点 $\varphi'(a)\cdot\varphi'(b) < 0$，取中点。

收敛快，计算大。

~~黄金分割法~~：若只有函数值，不用导也可缩小

选 a、b 端点，$x_1 = a + 0.382(b-a)$ $x_2 = a + 0.618(b-a)$

$\varphi(x_1)$ 比 $\varphi(x_2)$

舍弃大的一边。

收敛慢。

例：$f(x)=(x-2)^2$　$x_k=0$.

$\nabla f(x)=2(x-2)\big|_{x_k=0}=-4$　$d_k=-\nabla=4$.

$\varphi(\alpha)=f(0+\alpha\cdot 4)=(4\alpha-2)^2$.

$\varphi'(\alpha)=32\alpha-16=0$　$\alpha=\frac{1}{2}$.

$x_{k+1}=0+0.5\times 4=2$

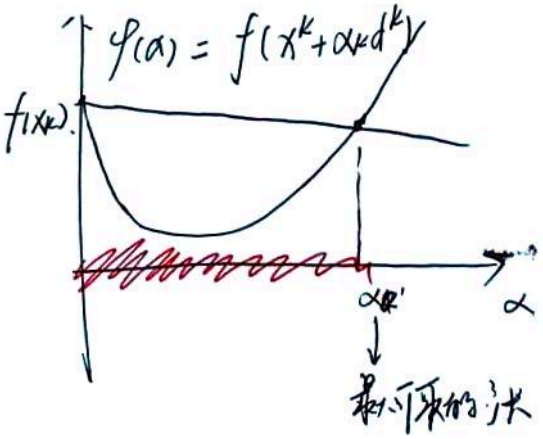
非精确：不追求最优步长，只要够划算即可

"划"的准则？

Armijo：$f(x_k+\alpha_k d_k)\le f(x_k)+c_1\alpha_1\nabla f(x_k)^T d_k$.

真实的下降至少要达到切线预测的那个百分比：c_1

几何上，右



右边 $l(\alpha)=\varphi(0)+c_1(\nabla f_0(x_1))^T d^k\cdot\alpha$.

$\varphi(0)=f(x_k)$　$c_1(\nabla f_0(x_1))^T d^k$：k斜率

那如何找到合适的α_k呢？回溯法：先走一大步，不行就缩小.

例：$f(x)=x^2$　$x_k=1$.

$\nabla f(x_k)=2x\big|_{x_k=1}=2$. 搜索方向：$-\nabla=-2$.

Armijo参数：$c_1=0.1$. $\alpha_{max}=1$. $\gamma=0.5$

尝试：$\alpha=\alpha_{max}=1$. 新点 $x=1-2=-1$. $f(-1)=1$

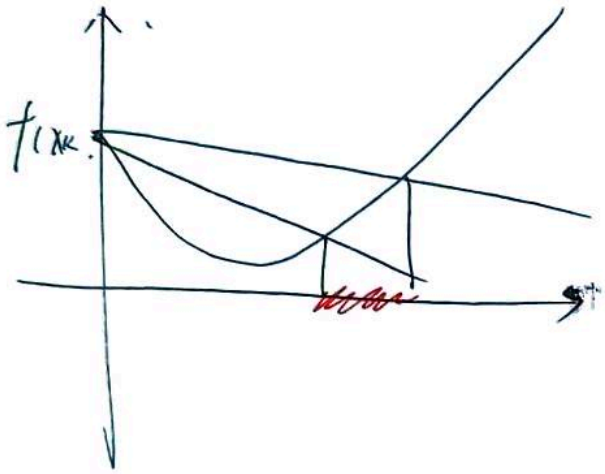
右边 $=f(1)+0.1\times 1\times 2\times(-2)=0.6$. (X).

缩小，$\alpha=0.5$

Goldstein 改良 Armijo. 不仅要下降够多，还要 不能太小

$$f(x_k+\alpha_k d_k) \le f(x_k)+c\alpha_k \nabla f(x_k) d_k \quad (\text{Armijo}).$$

$$f(x_k+\alpha_k d_k) \ge f(x_k)+(1-c)\alpha_k \nabla f(x_k)^T d_k \quad (c \in (0,\tfrac{1}{2})).$$

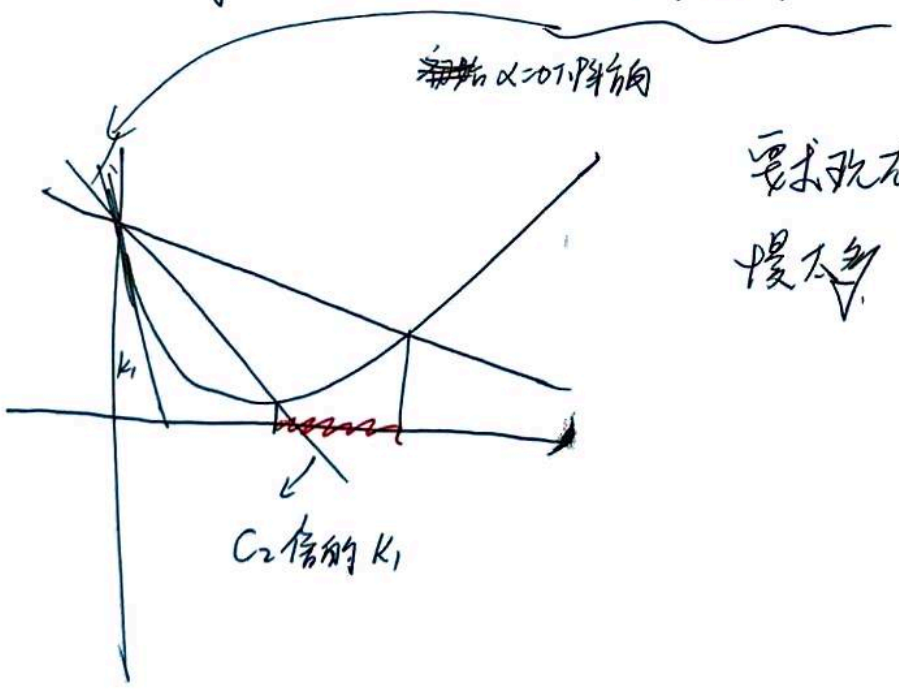


Wolfe 准则：改良 Goldstein 可能远离最优点的问题

引入导数信息：

$$f(x_k+x_k d_k) \le f(x_k)+c\alpha_k \nabla f(x_k) \cdot d_k \quad (\text{Armijo}).$$

$$\nabla f(x_k+\alpha_k d_k)^T d_k \ge c_2 (\nabla f_0(x_k))^T d_k$$



要求改点的下降速度不和比一开始慢太多

Grippo. 允许暂时上升的思想（在非凸问题中）.

不要求比上一个好. 比最近 M 步中最差的好一个可.

$$f(x_{k+1}+\alpha_k d_k) \le \max_{0\le j\le \min(k,M)} f(x_{k-j}) + c_1\alpha_k \nabla f(x_k)^T d_k$$

梯度类算法

核心思想：在当前位置，沿着函数下降最快的方向走小步.

$$d_k = -\nabla f(x_k).$$

初始：设置起点 x_0，学习率 α（步长）

- 固定
- 递减
- 精确/非精确线搜索
- 自适应步长

```
while (||∇f(x)|| > ε):
    grad = ∇f(x^k)
    d_k = - grad
    x_{k+1} = x^k + α · d_k
```

~~梯度下降的不动点~~

固定步长的梯度下降法

前提：$f_0(x)$ 是梯度利普希茨连续的凸函数.

- f_0 凸
- $\nabla f_0(x)$ L-Lipschitz
- 固定步长，$0<\alpha<\frac{2}{L}$（最优 $\frac{1}{L}$）

方向 L：$\|\nabla f_0(x) - \nabla f_0(y)\| \le L\|x-y\|$

$\Leftrightarrow$ 等价：$\nabla^2 f_0(x) \preceq LI$

函数值一定收敛到最小值 $f_0(x_k) \to f_0(x^*)$. 收敛速率 $O(\frac{1}{k})$.

$f_0(y) \geq f_0(x) + \langle \nabla f_0(x), y-x \rangle + \frac{\mu}{2}\|x-y\|^2$. ⇒ 最小值唯一.

若 $\begin{cases} f_0 \ \mu\text{-强} \\ \nabla f_0 \text{ 是 } L\text{-lipschitz} \\ \text{步长: } 0 < \alpha < \frac{2}{\mu+L} \end{cases}$ 收敛速率: $O\left((1-\frac{2\alpha\mu L}{\mu+L})^k\right)$.

何时步长最长?

使 $(1-\frac{2\alpha\mu L}{\mu+L})$ 尽可能小, 即 $\alpha \in (0, \frac{2}{\mu+L})$



$k=5$



$k=1$

去不同方向上的弯曲程度差异.

$(\frac{L-\mu}{L+\mu})^2$ 是 (0,1) 内的数. $k=\frac{L}{\mu}$ 决定收敛速度. $\begin{cases} k=1 \text{ 可一步收敛} \\ k \to \infty \text{ 收敛慢} \end{cases}$

例: $f(x_1, x_2, x_3) = (x_1-1)^2 + 2(x_2+1)^2 + 5(x_3-2)^2$ 初: $(0,0,0)$.

① $\nabla f = \begin{pmatrix} 2(x_1-1) \\ 4(x_2+1) \\ 10(x_3-2) \end{pmatrix}$ $\nabla f(x_0) = \begin{pmatrix} -2 \\ 4 \\ -20 \end{pmatrix}$

② Hessian $\nabla^2 f = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 10 \end{pmatrix}$ $\lambda_1=2\ \lambda_2=4\ \lambda_3=10$.

$\mu = \min(\lambda_i)$. $L = \max(\lambda_i)$.

$k=5$.

最优步长: $\frac{2}{\mu+L} = \frac{1}{6}$

$$x_1 = x_0 + \alpha \cdot d_k = (0,0,0) - \frac{1}{6}\begin{pmatrix} -2 \\ 4 \\ -20 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} \\ -\frac{2}{3} \\ \frac{10}{3} \end{pmatrix}$$

次梯度法

Why：梯度下降法前提：每个点都可微.

若不可微的 2, 故呢.

函数凸性保证了：任一点 存在"支撑超平面"

定义. $f(y) \geq f(x) + \langle g, y-x \rangle$ g为一个次梯度. 所有次梯度的集合→次微分 $\partial f(x)$.

性质：若 f 在点 x 可微. $\partial f(x) = \{\nabla f(x)\}$.

x^* 是 $\min_x f(x)$ 的最优点 $\Leftrightarrow 0 \in \partial f(x^*)$.

次梯度方法. 用凸性、代替可微性. 用次梯度代替梯度. 以速度换范围.

$\begin{cases} f \text{是凸函数} \\ f \text{自身是 } G\text{-Lipschitz 的} \\ \text{最优解存在} \end{cases}$ 解收敛. $\begin{cases} \text{步长} & \text{收敛情况} \\ \text{固定} & \text{收敛到邻域} \\ \alpha_k = \frac{1}{k+1} & O(\frac{1}{\ln k}) \\ \alpha_k = \frac{1}{\sqrt{k+1}} & O(\frac{\ln k}{\sqrt{k}}) \end{cases}$

例子：$\min f(x) = |x_1| + |x_2| + |x_3| = \|x\|_1$

$$\partial |x_i| = \begin{cases} 1 & x_i > 0 \\ -1 & x_i < 0 \\ [-1,1] & x_i = 0 \end{cases} \qquad \partial \|x\|_1 = \partial x_1 \times \partial x_2 \times \partial x_3$$

↑ 笛卡尔积

初始化：$x_0 = (2, -1, 0)$. $\alpha = 0.5$

次梯度 $g_0 = (1, -1, 0.5)$

↑ 可选.

更新：$x_1 = x_0 - \alpha g_0 = (2, -1, 0) - (1, -1, 0.5) \cdot \frac{1}{2} = (\frac{3}{2}, -\frac{1}{2}, -\frac{1}{4})$

坐标下降法

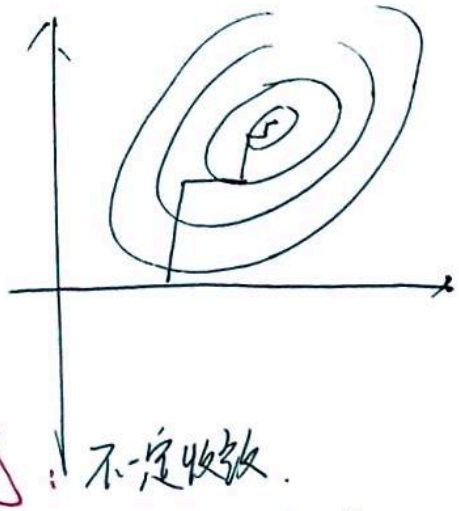
Why? 梯度下降：必须求整梯度/次梯度，代价高

我每次只动一个变量(维度)。

How

等价于之：$\min_{x_1 \cdots x_n} f(x_1, \cdots x_n)$ 拆成固定化一个

每步只沿一个方向，将该维调到最优



对每个维：

$$x_i^{k+1} \leftarrow \underset{x_i}{\operatorname{argmin}} f(x_1^{k+1} \cdots x_{i-1}^{k+1}, x_i^k, x_{i+1}^k)$$

⚠ 不一定收敛。

收敛也不一定最优

若连续可微凸函数，则为 f^*。

若凸但不连续可微，则不一定为 x^*。

复合型优化问题.

$$\min_x f_0(x) := g(x) + r(x)$$

$g(x)$: 可微凸函数, 非光滑 ↑

$r(x)$: 损失函数, 光滑 ↑

若用传统次梯度, 速度慢. 没充分利用 $g(x)$ 的光滑性.

邻近梯度法.

核心思想: 光滑的用梯度, 非光滑的给邻近算子处理.

邻近算子:

$$prox_{\alpha r}(x) := \arg\min_u \left\{ r(u) + \frac{1}{2\alpha}\|u-x\|_2^2 \right\} \quad \forall x.$$

例

二阶展开

$$x^{k+1} = \arg\min_u \left\{ r(u) + g(x^k) + \nabla g(x^k)^T(u-x^k) + \frac{1}{2\alpha_k}\|u-x^k\|_2^2 \right\}$$

已经做了一次梯度下降

$$= \arg\min_u \left\{ r(u) + \frac{1}{2\alpha_k}\|u-(x^k-\alpha_k\nabla g(x^k))\|^2 \right\}$$

$$= prox_{\alpha_k r}(x^k - \alpha_k \nabla g(x^k)).$$

邻近梯度法的迭代式.

可分步骤解决.

$$x^{k+\frac{1}{2}} = x^k - \alpha_k \nabla g(x^k). \qquad \text{收敛速率 } O\left(\frac{1}{k}\right).$$

$$x^{k+1} = prox_{\alpha_k r}(x^{k+\frac{1}{2}}).$$

示性函数

先验信息才投资.

$prox_{\delta_C}(x) \Rightarrow u_i = \begin{cases} a_i & x_i < a_i \\ x_i & a_i \le x_i \le b_i \\ b_i & x_i > b_i \end{cases}$

宁多想别也丢掉回来.

软阈值.

全投可交.

$t \ge 0$: $t \ge 0$. $\alpha t + \frac{1}{2}(t-x_i)^2$

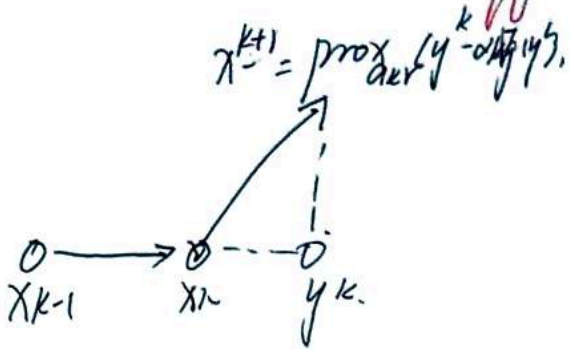
$\alpha + (u-x_i) = 0$

$u = x_i - \alpha$ ....

加速近端梯度法.

充分利用历史信息.（x_{k-1}到x_k的惯性）.

$$y^k = x^k + \theta_k(\theta_{k-1}^{-1} - 1)(x^k - x^{k-1}).$$



$$x^{k+1} = \arg\min_u \{ r(u) + g(y^k) + \nabla g(y^k)(u - y^k) + \frac{1}{2\alpha}\|u - y^k\|^2 \}$$

$$= \text{prox}_{\alpha_k r}(y^k - \alpha_k \nabla g(y^k)).$$

牛顿法

why? 梯度下降法中 有 L-lipschitz 假设.

意味着：仅用一个固定曲率的碗 绕住乙极. 不管实际乙极的曲率.

那何不利用乙极本身的曲率

在 x^k 处选择牛顿方向 $-\nabla^2 f_0(x^k)^{-1}\nabla f_0(x^k)$ 作为下降方向 d_k.

$$x^{k+1} = x^k - \nabla^2 f_0(x^k)^{-1}\nabla f_0(x^k) \quad (\alpha_k = 1).$$

性质：

若初值 x^0 足够近乙极，则收敛速度 Q-二次

例：二次乙极.

$$f(x) = \frac{1}{2}x^T Q x + b^T x. \quad Q \succ 0$$

$$\nabla f(x) = Qx - b.$$

$$\nabla^2 f(x) = Q.$$

$$d^k = -\nabla^2 f(x^k)^{-1}\nabla f(x^k) = -Q^{-1}(Qx^k - b).$$

$$x^{k+1} = x^k - Q^{-1}(Qx^k - b) = Q^{-1}b.$$

拟牛顿法

思想：构造 $\nabla^2 f_0(x_k)$ 的近似矩阵 B_k 或 $\nabla^2 f_0(x^k)^{-1}$ 的近似阵 H_k. 计算↓.

先得拟牛顿方向 d_k.

$$\min_d \; f_0(x^k) + \nabla f_0(x^k)^T d + \frac{1}{2} d^T B_k d.$$

? 左乘啥?

泰勒初展开：$f_0(x_{k+1}+d) \approx f_0(x_k) + \nabla f_0(x_k)^T d + \frac{1}{2} d^T H d$.

实际上，找最佳下降方向.

然后线搜索找步长.

更新 x^{k+1}.

更新 B_{k+1}.

~~约束优化算法~~：由于约束不可直接用"无约束方法"（可行域问题）.

~~罚函数~~. 核心问题：如何处理约束？

$$\min_x \ f_0(x).$$

$$s.t.\ h_i(x)=0 \quad i=1\cdots p.$$

核心思想：约束问题 $\longrightarrow$ 无约束问题.

罚函数法：对可行域外的点，施加"惩罚"来代替原可行域约束.

惩罚因子.

$$P_\sigma(x,\sigma)=f_0(x)+\frac{\sigma}{2}\sum_{i=1}^{p}|h_i(x)|^2$$

对可行域外的点 惩罚为正.

内 0.

然后：调用无约束算法求解.

σ 小：关心 $f(x)$，不关心约束.

σ 大：关心约束.

惩罚因子

$$\min_{x\in S} f(x) = \min_{x\in S}\{f(x)+\sigma p(x)\}$$

$$\geq \min_{x\in\mathbb{R}^n}\{f(x)+\sigma p(x)\}$$

$\theta(\sigma)=\min_x\{f(x)+\sigma p(x)\}$.

$\theta(\sigma)$ 为提供了下界.

若 $\sigma_1>\sigma_2$，结论？

$\theta(\sigma_1)>\theta(\sigma_2)$ ↑. 矛盾

↓

找上界.

$\max_\sigma \theta(\sigma) \Leftrightarrow \lim_{\sigma\to\infty}\theta(\sigma)$.

收敛性

若取单个 $\to\infty$ $P_\sigma(x,\sigma)$ 收敛. x^{k+1} 是全局最优解.

问题：易出现数值问题.

例： $\min_x f_0(x) = \|x\|_2^2 := x_1^2 + x_2^2$

s.t. $h(x) = x_1 + x_2 - 1 = 0$.

构造二次罚函数：

$P_0(x,\sigma) = x_1^2 + x_2^2 + \frac{\sigma}{2}(x_1+x_2-1)^2$. 固定 σ. 用梯度下降法.

求梯度.

$$grad = \begin{pmatrix} 2x_1 + \sigma(x_1+x_2-1) \\ 2x_2 + \sigma(x_1+x_2-1) \end{pmatrix}$$

$x^{k+1} = x^k - \alpha g \nabla f_0(x^k)$.

设初始点为 (0.0) $\sigma = 1$. $\alpha = 0.5$.

$$g\nabla f_0(x_0) = \begin{pmatrix} -1 \\ -1 \end{pmatrix}. \quad x^{k+1} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - 0.5\begin{pmatrix} -1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}.$$

framework

Step 0：取初始点 x^0. $\sigma_1 > 0$. $\varepsilon > 0$. $k_i = 1$.

Step 1. 以 x^{k-1} 为初始点.
求解无约束优化问题. 得到解 x^k.

Step 2：若 $\sigma_k P(x^k) < \varepsilon$. Stop.

step 3：更新 $\sigma_{k+1} > \sigma_k$. $k = k+1$. 转 step 1.

增广拉格朗日乘子法. 不要求 $\sigma \to +\infty$. 如何优化 | 想构造KKT点.

$$L_\sigma(x,\lambda) = f_0(x) + \sum_{i=1} \lambda_i h_i(x) + \frac{\sigma}{2} \sum_{i=1} |h_i(x)|^2$$

拉格朗日法 — 方向纠偏 — 引入对偶信息.

罚函数法 — 力度纠偏 — 缓解病态.

等价于目标函数加了 $\frac{\sigma}{2}\|Ax-b\|_2^2$.

原 $x^* =$ 对 x^*.

$$(ALM): \begin{cases} x^{k+1} = \arg\min_x L_{\sigma_k}(x, \lambda^k). & \text{解一个"无约束问题"} \uparrow \text{固定 } \lambda^k \text{ 与 } \sigma_k \\ \lambda_i^{k+1} = \lambda_i^k + \sigma_i h_i(x^{k+1}). & \text{更新乘子: 记仇: } h_i(x^{k+1}) \text{ 一入个下次更敏感} \\ \sigma_{k+1} = \rho \sigma_k. & \text{更新罚因子:} \end{cases}$$

- 特点: 原问题与对偶问题的KKT条件~~被~~等价.

  {x^*} 为有收敛点列 $\{x^k\}$ 收敛到原问题KKT点.

思想:

若原问题KKT

$$\nabla f_0(x^*) + \sum_i \lambda_i^* \nabla h_i(x^*) = 0.$$

第 k 步子问题KKT

$$\nabla f_0(x^{k+1}) + \sum_i (\lambda_i^k + \sigma_k h_i(x^{k+1})) \nabla h_i(x^{k+1}) = 0.$$

$$\begin{cases} h_i(x^{k+1}) \to 0. \\ \lambda_i^k \approx \lambda^{k+1} + \sigma h_i(x^{k+1}) \text{ 来之更新.} \end{cases}$$

约束收敛靠乘子. 罚项只辅助.

代替为 $\sigma h_i N \to \infty$.

因此 $\sigma_k \to +\infty$ 不需

例：

$$\min_{x\in\mathbb{R}^n} \|x\|_1 \quad \text{s.t. } Ax=b. \qquad (P).$$

$$L_\sigma(x,\lambda) = \|x\|_1 + \langle \lambda, Ax-b\rangle + \frac{\sigma}{2}\|Ax-b\|_2^2$$

引求解P的ALM为 $(\rho>1,\ \bar{\sigma}\le+\infty)$.

$$\begin{cases} x^{k+1} = \arg\min_x \{L_{\sigma_k}(x,\lambda^k)\} \\ \lambda^{k+1} = \lambda^k + \sigma_k(Ax^{k+1}-b) \\ \sigma_{k+1} = \min\{\rho\sigma_k, \bar{\sigma}\} \end{cases}$$

ADMM 交替方向乘子

问题：具有两块可分结构的线性约束优化问题

$$\min_{x\in\mathbb{R}^n,\, y\in\mathbb{R}^m} \quad f(x)+g(y) \quad \text{(均不妨设为凸)}$$

$$s.t. \quad Ax+By=b.$$

若用 ALM，先 $\min_{x,y} L_A(x,y,\lambda,\sigma)$ 这一次，x,y 有交叉项，不可分离，且要同时对 x,y 做优化。

思想：对 x,y 依序作极小化，一个击破

$Step_0$：初始点 $x^0,\lambda^0,\sigma_0,\varepsilon>0,k=0$，$t$：对偶步长

$Step_1$：$y^{k+1}=\arg\min_y L_A(x^k,y,\lambda^k,\sigma_k)$ // 固定 x,λ,σ 优化 y

$x^{k+1}=\arg\min_x L_A(x,y^{k+1},\lambda^k,\sigma_k)$ // 固定 y,λ,σ 优化 x

$Step_2$ 若 $\|Ax+By-b\|<\varepsilon$，stop.

$Step_3$：$\lambda^{k+1}=\lambda^k+t\sigma_k(Ax^{k+1}+By^{k+1}-b)$. // 同 ALM.

$\sigma_{k+1}=\rho\,\sigma_k$.

收敛性：$f(x),g(y)$ 均适当闭凸，(P) KKT 解非空.

每个迭代子问题强凸，则由 ADMM 迭代得到的序列

$\{(x^k,y^k,\lambda^k)\}$ 收敛到 (P) 的一个 KKT 点.

求解LASSO问题.

$$\min_{x} \frac{1}{2}\|Ax-b\|^2+\mu\|x\|_1$$

引入辅助变量 $y=x$.

$$\min_{x,y} \frac{1}{2}\|Ax-b\|^2+\mu\|y\|_1$$

$$\text{s.t. } x=y.$$

$$L_\sigma(x,y,\lambda)=\frac{1}{2}\|Ax-b\|^2+\mu\|y\|_1+\lambda^T(x-y)+\frac{\sigma}{2}\|x-y\|_2^2$$

$$\begin{cases} x^{k+1}=\arg\min_x L_\sigma(x,y^k,\lambda^k) \\ \quad =\arg\min_x \left\{\frac{1}{2}\|Ax-b\|^2+\frac{\sigma}{2}\|x-y^k+\sigma^{-1}\lambda^k\|^2\right\} \\ \quad =(A^TA+\sigma I)^{-1}(A^Tb+\sigma y^k-\lambda^k) \quad \nabla=0. \\ y^{k+1}=\arg\min_y L_\sigma(x^{k+1},y,\lambda^k) \\ \quad =\arg\min_y \left\{\mu\|y\|_1+\frac{\sigma}{2}\|x^{k+1}-y+\sigma^{-1}\lambda^k\|^2\right\} \quad \text{凑邻近算子的形式} \\ \quad =\text{prox}_{\sigma^{-1}\mu\|\cdot\|_1}(x^{k+1}+\sigma^{-1}\lambda^k) \\ \lambda^{k+1}=\lambda^k+\tau\sigma(x^{k+1}-y^{k+1}) \end{cases}$$

着重设定实例让两个部分可分

从而交替更新.